KNOWLEDGE BASE (KB) TRONG HỆ THỐNG TRUY HỒI THÔNG TIN (IR)

Knowledge Base (KB) là gì?

- Trong IR, **Knowledge Base** là **tập tài liệu tri thức có quản trị**, gồm:
  - **Nội dung** (text, bảng, hình, file đính kèm…)
  - **Cấu trúc & quan hệ** (chương–mục–điều, bài viết–file đính kèm, trang–chuyên mục)
  - **Metadata** (nguồn, ngày ban hành, hiệu lực, đối tượng áp dụng, đơn vị ban hành…)
  - **Vòng đời** (phiên bản, còn/hết hiệu lực, lịch sử cập nhật)
- KB không chỉ là "văn bản", mà là "văn bản *có tổ chức và có quản trị*".

Phân biệt: KB vs Database vs Knowledge Graph

- **Database**: dữ liệu cấu trúc (bảng, bản ghi), tối ưu truy vấn chính xác.
- **KB cho IR**: thường là dữ liệu bán cấu trúc/phi cấu trúc (văn bản), tối ưu cho "tìm kiếm liên quan".
- **Knowledge Graph**: tri thức dạng thực thể–quan hệ (entity-relation), mạnh cho truy vấn quan hệ ("A thuộc khoa nào?").

Vai trò của KB trong IR

- **KB quyết định : Đúng – Đủ – Mới – Tin**
  - **Đủ (Recall)**: KB thiếu tài liệu → không thể trả đúng dù truy vấn hay.
  - **Đúng (Precision)**: KB nhiều trùng lặp, lẫn bản cũ → kéo nhầm tài liệu.
  - **Mới (Freshness)**: thông báo/lịch/quy định thay đổi → KB không cập nhật là trả sai.
  - **Tin (Trust/Audit)**: có nguồn, có trích dẫn, có phiên bản → người dùng kiểm chứng được.

Cấu trúc một KB đúng chuẩn cho IR

Kiến trúc gồm 4 lớp:

- **Document Store**: lưu tài liệu gốc và bản trích xuất (HTML/PDF/DOC).
- **Metadata Store**: lưu trường thông tin (đơn vị ban hành, ngày hiệu lực, đối tượng…).
- **Chunk Store**: lưu các "đoạn" đã chia (điều/khoản/bước…).
- **Index**:
  - **Inverted index** (keyword/BM25)
  - **Vector index** (ngữ nghĩa)
  - **Graph index** (quan hệ thực thể)

Cách tạo KB cho IR: quy trình tổng quát

- Bước 1: Xác định phạm vi tri thức (Scope)
- Bước 2: Thu thập dữ liệu (Ingestion)
- Bước 3: Trích xuất nội dung (Extraction)
- Bước 4: Làm sạch & chuẩn hoá (Cleaning/Normalization)
- Bước 5: Gắn metadata và quản trị hiệu lực (Enrichment/Governance)
- Bước 6: Chia đoạn (Chunking)
- Bước 7: Lập chỉ mục (Indexing)
- Bước 8: Đánh giá & cải tiến (Evaluation)
- Bước 9: Cập nhật định kỳ (Freshness)

Một số KB/corpus dùng trong hệ thống IR thực tế

- **Wikipedia**, **Wikipedia tiếng Việt**
- **Wikidata/DBpedia**: tri thức dạng thực thể–quan hệ (hỗ trợ truy vấn factual, entity linking).
- **PubMed**: bài báo y sinh; IR học thuật và tra cứu nghiên cứu.
- **arXiv**: bài báo khoa học (đặc biệt CS/Toán/Lý)
- **Stack Overflow (Q&A corpus)**: tri thức dạng hỏi–đáp; tìm kiếm giải pháp kỹ thuật.
- **Enterprise KB**: Confluence/SharePoint/Notion nội bộ (quy trình, chính sách, hướng dẫn).
- **Help Center / Ticket KB**: Zendesk/Freshdesk + bài viết hỗ trợ khách hàng.

Để tối ưu hóa mô hình???

- **Chuẩn hoá nguồn và loại bỏ trùng**
- **Thiết kế chunking theo cấu trúc tài liệu** (điều/khoản/mục)
- **Bổ sung metadata tối thiểu** (ngày, nguồn, lĩnh vực, hiệu lực)
- **Chọn chiến lược index/truy hồi** (keyword + vector + hybrid nếu cần)
- **Đánh giá bằng tập câu hỏi chuẩn** (golden set) để đo recall/precision
- Tối ưu reranker, prompt, mô hình

Các bước tạo KB cho IR

- Xác định use-case + nhóm câu hỏi trọng điểm
- Lập danh sách nguồn (website, danh mục, file đính kèm)
- Thu thập theo sitemap/RSS/danh mục, lưu URL chuẩn
- Trích xuất nội dung (HTML + PDF/DOC), xử lý file đính kèm
- Làm sạch: bỏ boilerplate, chuẩn hoá text, bỏ lặp
- Thiết kế schema metadata + gắn metadata tự động + bổ sung thủ công
- Quản trị hiệu lực: phiên bản, thay thế, còn/hết hiệu lực
- Chunking theo cấu trúc nội dung (điều/khoản/bước/mốc thời gian)
- Index hybrid (keyword + vector) + rerank
- Đánh giá bằng bộ câu hỏi chuẩn + cải tiến theo log
- Thiết lập cập nhật định kỳ + giám sát chất lượng (tài liệu trống, OCR lỗi, URL chết)

Hệ thống tra cứu văn bản cho sinh viên

- Sinh viên thường tra cứu gì?
- Knowledge base nên tổ chức thế nào để “tìm đúng, trả nhanh”
- Chiến lược tìm kiếm phù hợp nhất cho trường đại học
- Trả kết quả kiểu nào để sinh viên tin và dùng thường xuyên?
- cập nhật và tránh “trả lời sai vì văn bản cũ”
- Đánh giá nhanh để biết hệ thống có ổn không

Hệ thống tra cứu văn bản cho sinh viên

- **Văn bản đã có trên website** thì bài toán "knowledge base" chủ yếu là làm sao **thu thập đúng – làm sạch tốt – gắn metadata chuẩn – cập nhật kịp thời**.
  - Knowledge base từ website gồm những "mảnh" nào
  - Pipeline chuẩn để "đổ" website vào KB
    - Thu thập (Crawl/Fetch)
    - Trích xuất nội dung (Extract)
    - Làm sạch & chuẩn hoá (Clean/Normalize)
    - Gắn metadata (Metadata/Enrich)
    - Chia đoạn (chunking) thế nào cho website?
    - Truy hồi cho sinh viên???
    - Xây dựng hệ thống truy hồi đoạn văn phục vụ bài toán hỏi–đápCập nhật KB khi website thay đổi

Bước 3: Thiết kế metadata (tối thiểu mà hiệu quả)

Metadata giúp: lọc đúng đối tượng + ưu tiên đúng hiệu lực

Trường	Ý nghĩa / ví dụ
doc_type	Quy chế / Hướng dẫn / Thông báo / Biểu mẫu / Lịch
issuer_unit	Phòng Đào tạo / CTSV / Tài chính / Khoa…
published_date	Ngày đăng trên website
effective_date – expiry_date	Ngày hiệu lực / hết hiệu lực (nếu có)
audience	Hệ đào tạo, khoá, khoa, chương trình
tags	Từ khoá nghiệp vụ: học phí, học lại, tốt nghiệp…
source_url	Link nguồn để mở và trích dẫn
attachments	Danh sách file đính kèm + URL

Bước 4: Chunking – chia đoạn để truy hồi đúng ngữ cảnh

Nguyên tắc: chia theo "cấu trúc nội dung", không chia theo ký tự

§ Quy chế / quy định

- Chia theo Chương → Điều → Khoản
- Giữ tiêu đề điều/khoản trong chunk
- Không cắt giữa câu điều kiện/ngoại lệ

✓ Thủ tục / hướng dẫn

- Chia theo "Hồ sơ", "Bước 1–2–3"
- Tách rõ: nơi nộp, thời hạn, lệ phí
- Liên kết biểu mẫu đính kèm

□ Thông báo / lịch

- Chia theo mốc thời gian & đối tượng áp dụng
- Tách phần "thời hạn" để ưu tiên
- Gắn tag "học kỳ/năm học" nếu có